

## 高等数学部分

### 极限定义:

$f(x)$  在  $x_0$  的某一去心邻域内有定义, 存在常数  $A$  使得, 给定任意小正数  $\varepsilon$ , 总存在  $\delta$  使得  $x$  满足,

$0 < |x - x_0| < \delta$ , 对应的  $f(x)$  满足不等式  $|f(x) - A| < \varepsilon$ .

去心邻域说明了极限定义没有必要在  $x_0$  处有定义. 并且由于  $x_0$  邻域必然包括左极限和右极限, 因此可以简单的通过左右极限是否相等来判断极限是否存在.(必要条件)

极限存在的判定准则?

准则 1: 夹逼准则: 若  $n > n_0$  时总有  $y_n \leq x_n \leq z_n$ , 且  $\lim_{n \rightarrow \infty} y_n = a$ ,  $\lim_{n \rightarrow \infty} z_n = a$ , 则  $\lim_{n \rightarrow \infty} x_n = a$

准则 2: 单调有界序列极限存在.

准则 3: 收敛序列并不一定单调, 但是存在极限, 因此利用柯西极限定理可证明其存在极限.

(充分必要条件)存在正数  $N, M$ , 使得当  $n > N, m > M$  时满足:  $|x_n - x_m| < \varepsilon$

### 连续定义:

连续的定义是通过极限来得到的. 极限中包含了去心邻域, 而连续的定义为非去心邻域.

函数  $y = f(x)$  在  $x_0$  的某一邻域内有定义. 满足  $\lim_{x \rightarrow x_0} f(x) = f(x_0)$ , 则说明函数连续.

判断函数连续的简单方法: 只需在极限存在的基础上, 在判断  $x_0$  处的值即可: 左右极限存在且相等, 且左极限值等于  $f(x_0)$ .

### 导数

一元函数导数定义:  $f'(x_0) = \lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$

由于  $f(x_0)$  包含在定义中, 因此可导必然连续. 判断导数存在的简单方法仍然可以通过左右极限是否相等来判断, 上式中左右极限给了新的名词 左导数右导数. 因此判断左右导数是否相等可以简单判断导数是否存在.

### 微分

微分定义: 函数  $y = f(x)$  在  $x_0$  的某一邻域内有定义, 在此区间内, 函数增量

$$\Delta y = f(x_0 + \Delta x) - f(x_0) = A \times \Delta x + o(\Delta x)$$

其中  $A$  不依赖  $\Delta x$ ，则称函数可微。其中增量关键部分(舍去了高阶无穷小)  $A\Delta x = dy$ ，给定了一个新名词微分  $dy$ 。对于一元函数，可微必然可导，两者互为充分必要条件。因为：

$$\Delta y = A\Delta x + o(\Delta x) \Rightarrow \frac{\Delta y}{\Delta x} = A + \frac{o(\Delta x)}{\Delta x} \Rightarrow A = \lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = f'(x_0)$$

因此微分又可以写成  $dy = f'(x_0)\Delta x$ 。由于  $dx = 1 \cdot \Delta x$ ，因此都写成微分的表达式：

$$dy = f'(x_0)dx \Rightarrow \frac{dy}{dx} = f'(x_0)$$

## 微分中值定理

**费马引理**：函数  $y = f(x)$  在  $x_0$  的某一邻域  $U(x_0)$  内有定义，且在  $x_0$  处可导，对任意  $x \in U(x_0)$

满足  $f(x_0) \leq f(x)$ ，则  $f'(x_0) = 0$ 。直观物理意义就是局部极小值点的导数必然为 0。当然，

改成局部极大值点也可以，只需对任意  $x \in U(x_0)$  满足  $f(x_0) \geq f(x)$  即可；


相关证明可通过导数的定义出来，求出左极限  $\geq 0$ ，右极限  $\leq 0$ ，因此导数  $= 0$ ；

**四个定理**：罗尔定理，拉格朗日中值定理，柯西中值定理，泰勒中值定理

**罗尔定理**：(1)闭区间  $[a, b]$  连续。(2)开区间  $(a, b)$  可导 (3)端点值相等  $f(a) = f(b)$ 。

则开区间内存在  $f'(x) = 0$ 。如图，很形象的一个图。条件(2)很重要，但是还需要条件(1)，因为

开区间可导，并不能保证边缘点连续。因此需要条件(1)来补充。罗尔定理的证明可从费马引理出发，证明此区间内存在局部最大值点或者局部最小值即可。



**拉格朗日中值定理**：罗尔定理有点严格，释放第三个条件可得到：拉格朗日中值定理。


(1)闭区间  $[a, b]$  连续。(2)开区间  $(a, b)$  可导

则区间内存在一点满足  $f(b) - f(a) = f'(x)(b - a)$ . 物理含义如图.

证明方法也很简单, 把  $f(x)$  掰平, 然后利用罗尔定理证明即可. 构造辅助函数:

$$g(x) = f(x) - \frac{f(b) - f(a)}{b - a}(x - a) + f(a)$$

利用罗尔定理:  $g'(x) = 0 \Rightarrow \frac{f(b) - f(a)}{(b - a)} = f'(x)$  得证.




柯西中值定理: 扩展到函数之间的导数关系.  $f(x), g(x)$

(1) 闭区间  $[a, b]$  连续 (2) 开区间  $(a, b)$  可导 (3) 对任意  $x \in (a, b)$ ,  $f'(x) \neq 0$ .

则存在  $\varepsilon \in (a, b)$  使得  $\frac{g(b) - g(a)}{f(b) - f(a)} = \frac{g'(\varepsilon)}{f'(\varepsilon)}$

物理含义不太直观, 但是也可以理解, 只需将  $f(x)$  当成原本的  $x$  轴即可. 坐标为  $(f(x), g(x))$



泰勒中值定理

洛必达法则

洛必达法则由柯西中值定理得到. 它可以处理  $0/0, \infty/\infty$  的问题.

(1) 当  $x \rightarrow a$  时,  $f(x), g(x)$  都趋向于 0;

(2) 在点  $a$  的某去心邻域内,  $f'(x), g'(x)$  存在且  $f'(x) \neq 0$

(3)  $\lim_{x \rightarrow a} \frac{g'(x)}{f'(x)}$  存在.

满足上述三个条件, 则可以证明.  $\lim_{x \rightarrow a} \frac{g(x)}{f(x)} = \frac{g'(x)}{f'(x)}$

证明: 由柯西中值定理可得:  $\frac{g(x)}{f(x)} = \frac{g(x) - g(a)}{f(x) - f(a)} = \frac{g'(\varepsilon)}{f'(\varepsilon)}$ , 其中  $f(a) = g(a) = 0$

两边取极限  $x \rightarrow a$ , 则  $\varepsilon \rightarrow a$ , 得证.

泰勒公式:

函数在某点的多项式逼近. 因为多项式有很强的拟合能力, 因此利用导数信息得到多项式的系数

利用函数值和导数信息求得: 拟合函数

$$p(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \dots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n$$

原函数在某一邻域内为拟合函数+高阶无穷小:  $f(x) = p_n(x) + o((x - x_0)^n)$ ,

但拟合是在邻域内才有较高的准确度, 不保证远处也有相同精度.

泰勒中值定理:

泰勒拟合公式的最后一项高阶无穷小可以通过柯西中值定理得到**准确表达式**.

高阶无穷小:  $R_n(x) = o((x - x_0)^n) = \frac{f^{(n+1)}(\varepsilon)}{(n+1)!}(x - x_0)^{n+1}$ , 其中  $\varepsilon$  介于  $x$  与  $x_0$  之间. 这也是

为什么叫做**中值定理**的原因, 通过**中间点确定边界点**的值.

当  $n=0$  时, 泰勒中值退化成拉格朗日中值:

$$f(x) = p_n(x) + R_n(x) \Rightarrow f(x_0) + f'(x_0)(x - x_0)$$

## 多元函数

微分关注的是增量, 求导关注的是导数值. 对于一元函数有:

$$\text{可微 } dy \Leftrightarrow \text{可导 } f'(x) \Rightarrow \text{连续} \Rightarrow \text{极限存在}$$

对于多元函数上述条件要发生改变: 没画双向的都是单向条件, 仅有充分性.

偏导连续  $\Rightarrow$  可微  $dz \Rightarrow$  连续  $\Rightarrow$  极限存在的

值得注意的是: 偏导存在  $\not\Rightarrow$  连续. 因为偏导是一维连续, 多元函数的连续是一个区域连续.

下面详细说明多元函数的偏导和微分的关系.

## 全微分与偏导

**全增量:**  $\Delta z = f(x + \Delta x, y + \Delta y) - f(x, y)$ , 其中  $x + \Delta x$  保证在  $x$  的邻域内.

如果全增量能化简到此形式, 其中  $A, B$  为常数. 则可称函数  $f$  在点  $(x, y)$  处可微.

$$\Delta z = A\Delta x + B\Delta y + o(\sqrt{(\Delta x)^2 + (\Delta y)^2})$$

**全微分:** 将可微的全增量的关键部分提取出来, 称其为全微分:  $dz = A\Delta x + B\Delta y$

**偏增量:**  $\Delta_x z = f(x + \Delta x, y) - f(x, y)$ , 利用一元函数的求导定义得到偏导数

**偏导数:**  $\frac{\partial z}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{\Delta_x z}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{1}{\Delta x} f(x + \Delta x, y) - f(x, y)$

可以证明: 全微分的  $A, B$  就是偏导数  $A = \frac{\partial z}{\partial x}, B = \frac{\partial z}{\partial y}$ . 利用全微分和一元求导定义即可证明.

**可微和偏导的关系:**

从可微的定义出发,  $\Rightarrow$  偏导数一定存在,  $\Rightarrow$  函数在区域内连续.  $\Rightarrow$  极限存在.

是否能从偏导数存在来得到可微的条件?

$$\Delta z = f(x + \Delta x, y + \Delta y) - f(x, y)$$

$$\Rightarrow \Delta z = f(x + \Delta x, y + \Delta y) - f(x, y + \Delta y) + f(x, y + \Delta y) - f(x, y)$$

$$\Rightarrow \Delta z = \left. \frac{\partial f}{\partial x} \right|_{(x, y + \Delta y)} \Delta x + \left. \frac{\partial f}{\partial y} \right|_{(x, y)} \Delta y$$

也就是说已知函数  $f$  在点  $(x, y)$  的偏导存在是不够的, 因为需要的是在  $(x, y + \Delta y)$  点的偏导存在,

同理按照上述方法推导, 需要在  $(x + \Delta x, y)$  点偏导也存在. 假如已知偏导在点  $(x, y)$  存在, 只

需增加一个条件: 偏导连续. 即: 偏导存在且连续可得函数在点  $(x + \Delta x, y)$  可微.

## 方向导数与梯度:

导数的概念是函数  $f$  的微分与  $x$  的微分相除而得. 对于多元函数情况类似, 但是对分母的选择却多了一些变化空间,  $\Delta l = \sqrt{(\Delta x)^2 + (\Delta y)^2}$ , 在保证  $\Delta l$  为单位长度的前提下, 可以选择不同比例系数的  $\Delta x$  和  $\Delta y$ . 由此求出来的导数也不一样, 因此为多元函数的求导定义了方向导数.

假设以  $\vec{l}$  方向作为增量, 函数可微. 则全微分表达式为:

$$\Rightarrow \Delta z = f(x + \Delta l \cos \alpha, y + \Delta l \cos \beta) - f(x, y)$$

$$\Rightarrow \Delta z = \frac{\partial f}{\partial x} \cdot \Delta l \cos \alpha + \frac{\partial f}{\partial y} \cdot \Delta l \cos \beta + o(\Delta \vec{l})$$

$$\Rightarrow dz = \frac{\partial f}{\partial x} \cdot \Delta l \cos \alpha + \frac{\partial f}{\partial y} \cdot \Delta l \cos \beta$$

$$\Rightarrow \frac{dz}{d\vec{l}} = \frac{\partial f}{\partial x} \cos \alpha + \frac{\partial f}{\partial y} \cos \beta$$

由于  $\Delta l$  为单位值,  $\alpha, \beta$  由  $\vec{l}$  控制, 因此不同方向的选择会得到不同的导数值.

有没有一个最大的方向向量? --- 梯度的方向可以得到最大的方向导数.

因为方向导数等于两个向量的点乘, 同向时点乘最大, 如下:

$$\frac{dz}{d\vec{l}} = \left( \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) \cdot (\cos \alpha, \cos \beta)$$

因此设梯度为:  $\vec{G} = \frac{\partial f}{\partial x} \vec{e}_x + \frac{\partial f}{\partial y} \vec{e}_y$ . 注意梯度是个向量!! 但长度不一定为 1.

## 多元积分:

了解即可, 详情参考电磁学.

高斯公式: 通量的面积分 = 散度的体积分

斯托克斯公式: 环量的线积分 = 旋度的面积分.

## 概率论部分

贝叶斯公式:

$$P(w_i | D) = \frac{p(D | w_i) p(w_i)}{\sum_j p(D | w_j) p(w_j)}$$

其中  $P(w_i | D)$  为后验概率,  $p(D | w_j)$  为似然概率,  $p(w_j)$  为先验概率. 详情参见机器学习贝叶斯部分.

## 常见离散分布

**0-1 分布:** (伯努利分布, 两点分布):  $p(x=1) = p$ ,  $p(x=0) = 1-p$

**二项分布:** 名字来自牛顿二项式,  $p(X=k) = C_n^k p^k (1-p)^{n-k}$

二项分布相当于多次掷硬币, 每次结果满足 0-1 分布, 各次实验之间独立, 结果累加.

**泊松分布:**  $p(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}$ , 其中  $\lambda > 0$

泊松分布的期望和方差都为  $E[X] = \lambda$ ,  $Var[X] = \lambda$ . 推导也很简单, 就按期望定义式即可.

实际上当二项分布的  $p$  很小时, 可以用泊松分布来逼近而二项分布:

**证明:** 将  $p = \lambda / n$  代入二项分布, 得到:

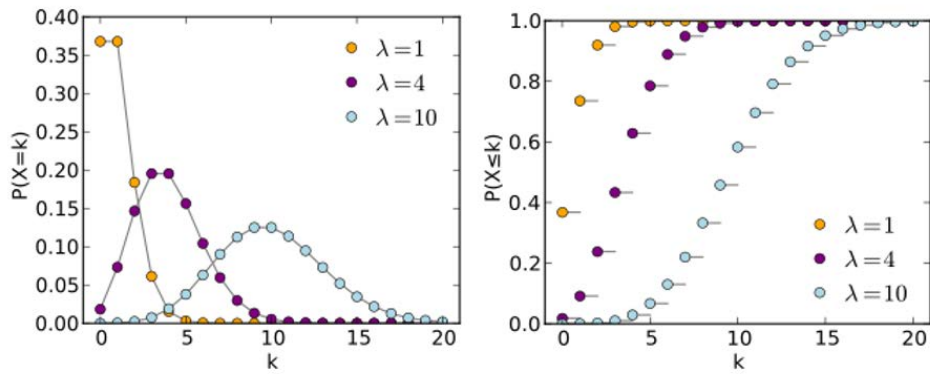
$$p(X=k) = \frac{n!}{k!(n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

由于  $\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$ , 代入上式得到:

$$\lim_{n \rightarrow \infty} \frac{n!}{k!(n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \Rightarrow \lim_{n \rightarrow \infty} \frac{n!}{n^k (n-k)!} \left(1 - \frac{\lambda}{n}\right)^{-k} \frac{\lambda^k}{k!} e^{-\lambda} = \frac{\lambda^k}{k!} e^{-\lambda}$$

其中由于  $n \rightarrow \infty$ , 因此  $\left(1 - \frac{\lambda}{n}\right)^{-k} = 1$ ,  $\frac{n!}{n^k (n-k)!} = \frac{n(n-1)\dots(n-k+1)}{n^k} = 1$ .

因此  $p(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$  得证.



如何估计出参数  $\lambda$ ，第一种就是利用二项分布  $\lambda = np$ ，第二种可用 MLE 极大似然估计。

$$L(\lambda) = \ln \prod_i f(k_i | \lambda) = \sum_i \ln \frac{\lambda^{k_i}}{k_i!} e^{-\lambda} = n\lambda + \sum_i k_i \ln \lambda + \sum_i \ln(k_i!)$$

其中  $n$  为实验次数,  $k_i$  为每次实验得到的  $k$  值。

对  $L$  求导得到驻点,  $\lambda = \sum_i k_i / n$ ，求二阶导发现驻点处二阶导  $< 0$ ，因此判断出是极大值点。

实际上假设每次实验满足二项分布，利用极大似然估计求出  $p = \left( \sum_i \frac{k_i}{m} \right) / n$  其中  $m$  为每次实验

的投掷次数,  $n$  为实验次数。而方法一得出的  $\lambda = mp$ ，因此方法一和方法二实际上是等价的。

**几何分布:**  $p(X = k) = q^{k-1}p$ ，相当于 0-1 分布的实验中求前  $k-1$  次失败,第  $k$  次成功的概率。

这种分布的特点是无记忆性，每次抽取都是于 0-1 分布，不会因为抽取次数而改变。

**超几何分布:** 有放回抽样  $p(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$ ，其中  $M$  为次品总数,  $N$  为全部产品总数。

$n$  为目标抽样数,  $k$  为抽到的次品数量。

## 常见连续变量分布

连续分布用概率密度函数  $f(x)$  和分布函数  $F(x = k) = p(x \leq k)$  来描述分布。

**均匀分布:**  $f(x) = \frac{1}{b-a}$ ，其中  $a \leq x \leq b$ ， $F(x) = \frac{x-a}{b-a}$ ，其中  $a \leq x \leq b$ ，

**指数分布:**  $f(x) = \lambda e^{-\lambda x}$ ，其中  $x > 0$ 。期望为  $E[xf(x)] = \frac{1}{\lambda}$ ， $\text{var}[X] = \frac{1}{\lambda^2}$

指数分布的特点是时间无关性，只和时间间隔有关，



**泊松过程:**  $P(N(t+\tau) - N(t) = k) = \frac{(\lambda\tau)^k}{k!} e^{-\lambda\tau}$ . 泊松分布相当于单位时间的泊松过程,  $\lambda$

被称为抵达率, 当时间间隔足够大时,  $k$  值分布会整体往右移动. 当  $k=0$  时, 泊松分布变为:

$p(k=0) = e^{-\lambda\tau}$ , 非 0 概率为:

$$p(X(\tau) > 0) = 1 - e^{-\lambda\tau} \Rightarrow f(X(\tau) > 0) = \lambda e^{-\lambda\tau}$$

也就从泊松分布得到了指数分布. 指数分布就是有人来就好, 泊松分布还可以统计人数.

指数分布的时间无关性: 假设把  $k=0$  当成原件成功运行,  $k>0$  表示器件损坏.

则旧原件和新原件的使用寿命仍然相等:

证明:

已知指数分布: 从 0 到  $t$  时刻不发生故障的概率  $p(t) = e^{-\lambda t}$

已知工作了  $s$  时间, 则未来  $s$  到  $s+t$  不发生故障的概率为

$$p(s+t | s) = \frac{p(s+t)}{p(s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}$$

得证.

**正态分布:** 期望为  $E[X] = u$ , 方差为  $Var[X] = \sigma^2$ . 概率密度函数为:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-u)^2}{2\sigma^2}\right)$$

正态随机变量的线性函数仍为正态随机变量.

极大似然和最大后验概率等相关知识可参见传统机器学习篇章.


# 信号与系统

**冲激定义：**  $\delta(t) = \frac{1}{\tau} (u(t + \tau / 2) - u(t - \tau / 2))$ . 物理意义是面积为 1 的信号.

宽度由阶跃函数 u 提供, 高度由  $1 / \tau$  提供.

**信号的冲激表达式：** 利用微积分的思想, 将函数通过阶跃函数进行分段表达.

如:  $f(t_1)[u(t - t_1) - u(t - t_1 - \Delta t)]$ , 表示在  $(t_1, t_1 + \Delta t)$  这段时间内的函数值  $f(t_1)$  的近似替代.



将分段信号累加可得: 可得信号的冲激表达式. 冲激表达式的好处是配合系统函数得到的.

$$f(t) = \sum_{t_1=-\infty}^{\infty} f(t_1)[u(t - t_1) - u(t - t_1 - \Delta t)]$$

$$\Rightarrow f(t) = \sum_{t_1=-\infty}^{\infty} f(t_1) \frac{[u(t - t_1) - u(t - t_1 - \Delta t)]}{\Delta t} \Delta t$$

$$\Rightarrow f(t) = \sum_{t_1=-\infty}^{\infty} f(t_1) \delta(t - t_1) \Delta t \Rightarrow \int_{-\infty}^{\infty} f(\tau) \delta(t - \tau) d\tau$$

**冲激的系统响应：** 冲激信号得到的零状态系响应 等价于 具有单位能量的零输入响应.

这是由冲激函数的性质决定的, 因为信号在  $t > 0$  时=0, 因此没有强迫响应, 瞬时的能量供应给了系统单位能量, 因此系统响应等效为零输入响应.

假设  $h(t)$ 为系统的冲激响应, 由于系统为 LTI(linear Time Invariance)系统, 响应可以累加, 因此

激励信号	响应信号	理论依据
$\delta(t)$	$h(t)$	定义
$\delta(t - \tau)$	$h(t - \tau)$	时不变特性
$\sum_{t_1=-\infty}^{\infty} f(t_1) \Delta t \delta(t - t_1)$	$\sum_{t_1=-\infty}^{\infty} f(t_1) \Delta t h(t - t_1)$	叠加性

并且由于信号的现实意义, 积分变量  $t_1 > 0$ , 且  $t > t_1$ , 因此上述式子可以继续化简得到系统响应:

$$r(t) = \int_0^t f(\tau)h(t-\tau)d\tau$$

此式的数学形式又被称为卷积. 其物理意义很明确: 历史信号对  $t$  时刻的响应的累计.

比如说  $t$  时刻, 最新的信号为  $f(t)$ , 系统对应的响应应为  $h(0)$ , 而前一秒信号  $f(t-1)$  的响应

遗留到  $t$  时刻的影响为  $h(1)$ , 结合所有对  $t$  时刻还有影响的响应, 得到的表达式就是卷积表达式.

## 傅里叶级数

上节讲了可以将信号表达为冲激函数的积分, 这是时域的分解, 接下来介绍一下频域的分解. 类似线性代数中, 将向量转换到矩阵的特征空间, 在矩阵的特征空间内的计算比较简单, 然后再将结果转化到普通空间得到计算结果, 这样的变换需要一个关键部分: 特征空间的正交基. 傅里叶

变换也找到了正交基,  $1, \cos(t), \cos(2), \dots, \cos(nt), \sin(t), \sin(2), \dots, \sin(nt)$

正交的定义: 当  $m \neq n$  时

$$\int_{-\pi}^{\pi} \cos(nt) \sin(mt) dt = \frac{1}{2} \int_{-\pi}^{\pi} \cos[(n-m)t] - \cos[(n+m)t] dt = 0$$

$$\int_{-\pi}^{\pi} \cos(nt) \cos(mt) dt = \frac{1}{2} \int_{-\pi}^{\pi} \cos[(n+m)t] + \cos[(n-m)t] dt = 0$$

将函数  $f(t)$  表达为正交基的线性组合:

$$f(t) = a_0 \cdot 1 + a_1 \cos(t) + b_1 \sin(t) + \dots + a_n \cos(nt) + b_n \sin(nt)$$

为保证上式成立, 需要  $\cos(t)$  与  $f(t)$  的周期一致. 如  $T$  为  $f(t)$  的周期, 则第一项为:  $\cos(\frac{2\pi}{T}t)$

为方便讨论  $f(t)$  的周期  $T$  均设为 1.

如何求出系数?:


$$\text{仅需左右两边乘以对应的正交基即可求出系数: } a_n = \frac{1}{\pi} \int_{-\pi}^{\pi} f(t) \cos(nt) dt$$

$$\text{当然对 } a_0 \text{ 情况特殊一些, 两边同时乘 1 积分: } a_0 = \frac{1}{2\pi} \int_{-\pi}^{\pi} f(t) dt$$

用  $\cos, \sin$  作为正交基比较直观, 实际上  $n < 0$  也是满足正交基的定义, 但由于历史原因(负频率没意义), 并不使用  $n < 0$  的正交基.

使用条件? 狄利克雷条件

- (1) 周期内间断点数目有限. (无穷间断点就不用玩了)
- (2) 周期内极大值极小值数量有限. (参考连续不可导函数)
- (3) 周期内信号可积. (积分值有限)



经过发展, 欧拉公式给了我们一个新途径: 用  $e^{jnw}$  作为正交基, 并且引入  $n < 0$  的正交基.

$$e^{jw} = \cos w + j \sin w$$

由上面的正交基的积分结果, 很容易证明  $e^{jnw}$  也是正交基. 当  $m \neq -n$  时, 注意是  $-n$ .

$$\int_{-\pi}^{\pi} e^{jnt} e^{jmt} dt = \int_{-\pi}^{\pi} (\cos nt + j \sin nt)(\cos mt + j \sin mt) dt = 0$$

将函数  $f(t)$  化为正交基的组合: 其中  $F(nw_1)$  表示系数,  $w_1$  表示基频.

$$f(t) = \sum_{n=-\infty}^{\infty} F(n) e^{jnt}$$


如何求出系数?: 仍然是乘正交基后积分.

$$\int_{-\pi}^{\pi} f(t) e^{-jmt} dt = \int_{-\pi}^{\pi} e^{jmt} \cdot \sum_{n=-\infty}^{\infty} F(n) e^{jnt} dt$$

$$\Rightarrow F(m) = \frac{1}{2\pi} \int_{-\pi}^{\pi} f(t) e^{-jmt} dt$$

由于指数正交基用到了负频率 因此图形为双边频谱, 且幅值大小为  $\cos$  正交基的  $1/2$ , 但是  $0$  点处是等高的. 如下图

帕塞瓦尔定理: 时域的平均功率等于  $P = \sum_{n=-\infty}^{\infty} |F_n|^2$ . 说明: 时域转频域空间也是符合能量守恒.



## 傅里叶变换

周期函数可以通过傅里叶级数展开, 而非周期函数则不能. 如果将非周期函数想象成周期  $T$  无穷大的周期函数则可进行傅里叶级数展开, 此时会出现如下情况:  $F(\omega_1), F(2\omega_1), \dots, F(n\omega_1)$  的

间隔  $\omega_1 = \frac{2\pi}{T} \rightarrow 0$ . 各个幅值在  $\omega$  为  $x$  坐标的图中会无限接近. 但幅值也会趋近 0.

$$F(m\omega_1) = \frac{1}{T} \int_{-T/2}^{T/2} f(t) e^{-jm\omega_1 t} dt \Rightarrow 0$$

由于帕塞瓦尔定理, 频域得到的能量和时域是一样的, 因此引入**频谱密度函数**来替代幅值

$$F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-j\omega t} dt$$

有了概率密度函数后, 看看之前的时域函数表达式.

$$f(t) = \sum_{n=-\infty}^{\infty} F(n\omega_1) e^{jn\omega_1 t} \Rightarrow f(t) = \frac{1}{T} \sum_{n=-\infty}^{\infty} F(\omega) e^{-j\omega t} = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega) e^{-j\omega t} d\omega$$

上述两式也叫做**傅里叶变换**和**傅里叶逆变换**.

**主要性质:**

若  $f(t)$  为实偶函数, 则  $F(\omega)$  为实偶函数. (可以将  $\exp(j\omega t)$  拆开得到  $\cos$  和  $\sin$  积分得到)

若  $f(t)$  为实奇函数, 则  $F(\omega)$  为虚奇函数. (可以将  $\exp(j\omega t)$  拆开得到  $\cos$  和  $\sin$  积分得到)

时域卷积 = 频域相乘:  $[f_1(t) * f_2(t)] \Rightarrow F_1(\omega) \cdot F_2(\omega)$

频域卷积 => 时域相乘:  $\frac{1}{2\pi} F_1(\omega) * F_2(\omega) \Rightarrow f_1(t) \cdot f_2(t)$

由此, 时域卷积可以求出系统响应, 可以通过傅里叶变换得到频域的表达式, 仅需相乘即可, 最后再进行傅里叶逆变换即可得到时域响应.

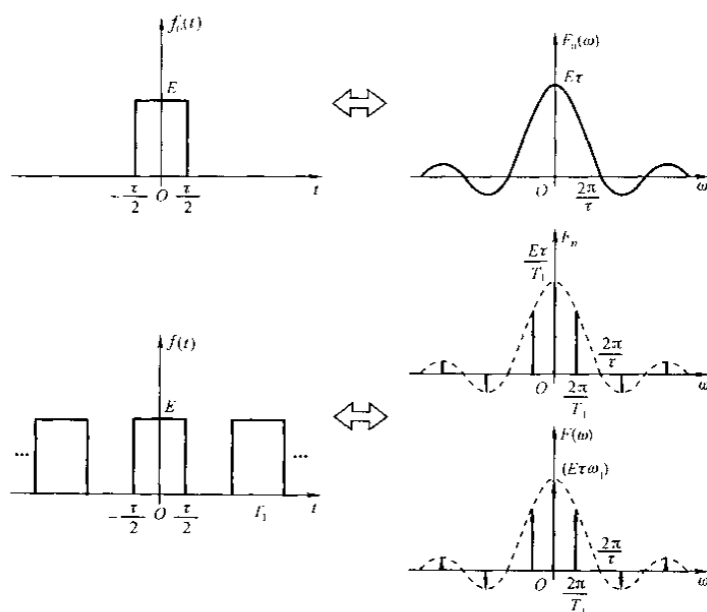
**自相关函数**的傅里叶变换为  $|F(\omega)|^2$ , 由此可以得到功率谱或者能量谱.

## 周期函数的傅里叶变换:

周期函数可以进行傅里叶级数展开, 非周期函数有傅里叶变换, 那么周期函数能否进行傅里叶变换? 可以--> 频谱为离散谱, 但是幅度为**冲激函数**. 这样的原因在于 傅里叶变换得到的是频谱的**密度**  $F(\omega)d\omega$  会等于  $F(n\omega_1)$ , 假设  $F(n\omega_1) = C$ , 则频谱密度  $F(\omega) = 2\pi C\delta(\omega)$ .

由于  $\left[ e^{jn\omega_1 t} \right] = 2\pi\delta(\omega - n\omega_1)$ , 其中  $[\ ]$  表示傅里叶变换.

于是:  $f(t) = \sum_{n=-\infty}^{\infty} F_n e^{jn\omega_1 t} \Rightarrow [f(t)] = 2\pi \sum_{n=-\infty}^{\infty} F_n \delta(\omega - n\omega_1)$ . 傅里叶变换为傅里叶级数的冲激序列.



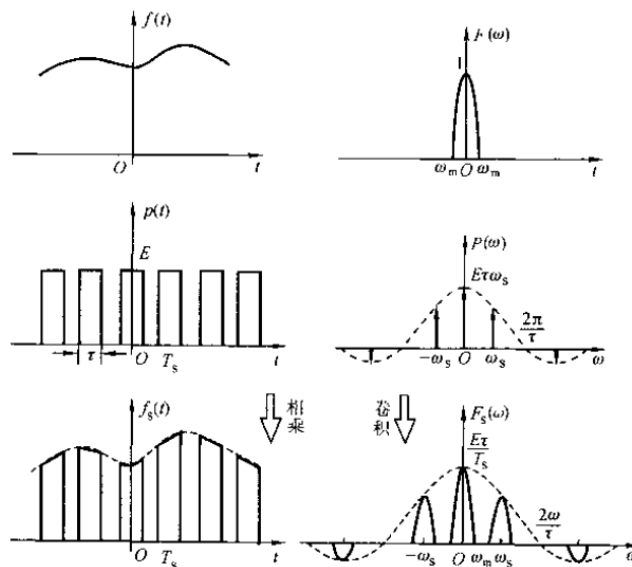
## 抽样

综合运用了卷积, 傅里叶级数与傅里叶变换的关系:

假设用矩形脉冲进行抽样:  $f_{sp}(t) = f(t)p(t)$

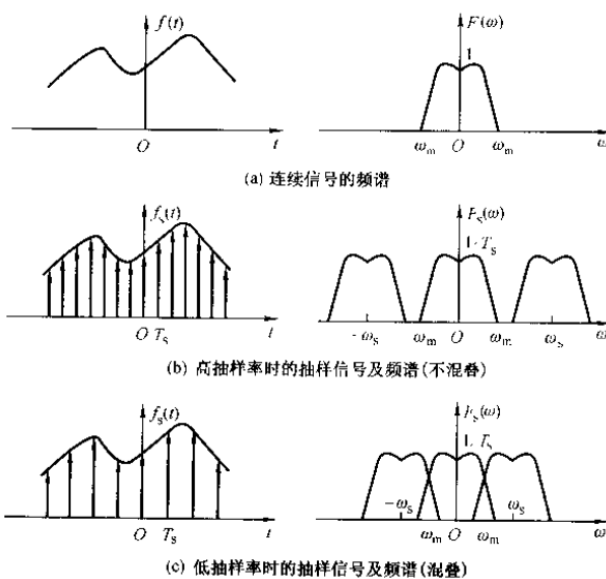
由于  $p(t)$  为周期函数, 因此其傅里叶变换为级数的冲激  $P(\omega) = 2\pi \sum_{n=-\infty}^{\infty} P_n \delta(\omega - n\omega_s)$

时域相乘 = 频域卷积/ $2\pi$ .  $F_s(\omega) = \frac{1}{2\pi} F(\omega) * P(\omega)$ . 如图:



如果抽样性能足够好—冲激序列，则整体上可以完全复制频谱，并且以采样频率  $\omega_s$  搬移。

这也可以说明奈奎斯特采样频率要大于信号最高频率的两倍的来源。



## 离散序列傅里叶变换.

离散时间序列的傅里叶变换也是一样，仍用正交基来表示，但是通过频域的正交基的组合来表示

频域. 如:  $X(e^{j\omega}) = FT[x(n)] = \sum_{n=-\infty}^{\infty} x(n)e^{-j\omega n}$ . 而正交基的系数就是时域表达式.

之前是时域周期连续，频域离散，现在是时域离散，频域周期连续.

逆变换: (求正交基的系数):  $x(n) = IFT[X(j\omega)] = \int_{-\pi}^{\pi} X(j\omega)e^{j\omega n} d\omega$

因为正交基的特性，基频的周期为  $T_w = [-\pi, \pi]$ ，因此频谱是有周期的。

FT 的使用条件：绝对可和  $\sum_{n=-\infty}^{\infty} |x(n)| < \infty$ ，可令  $X(j\omega) = 0$  得到该条件。

频域卷积定理：  $y(n) = h(n)x(n) \Rightarrow FT[y(n)] = \frac{1}{2\pi} H(j\omega) * X(j\omega)$

帕萨瓦尔定理：  $\sum_{n=-\infty}^{\infty} |x(n)|^2 = \frac{1}{2\pi} \int_{-\pi}^{\pi} |X(j\omega)|^2 d\omega$

离散周期序列傅里叶变换 DFT.

上文的离散序列满足可和条件，因此频谱连续，但是如果是离散序列也是周期序列呢？

此时又可以用时域的正交基了  $e^{j\frac{2\pi}{N}kn}$ 。正交性的简单证明：当  $k \neq m$  时  $\sum_{n=0}^{N-1} e^{j\frac{2\pi}{N}(k-m)n} = 0$ ，

当  $k = m$  时  $\sum_{n=0}^{N-1} e^{j\frac{2\pi}{N}(k-m)n} = N$ ，可用欧拉公式差分得证。

时域表达式为：  $\tilde{x}(n) = \frac{1}{N} \sum_{k=0}^{N-1} \tilde{X}(k) e^{j\frac{2\pi}{N}kn}$

如何求系数？正交基的求和即可：  $\tilde{X}(k) = \sum_{n=0}^{N-1} \tilde{x}(n) e^{-j\frac{2\pi}{N}kn}$

序列  $\tilde{x}(n)$  与  $\tilde{X}(k)$  都是周期为  $N$  的离散序列。

## 信息论

信息量与不确定度挂钩。不确定度与概率挂钩。于是信息量可以写成关于概率的函数。

自信息：  $I(x_i) = \log \frac{1}{p(x_i)}$ ，概率越小，则自信息越大。当然 100% 的必然事件没有信息量。

平均信息量(熵)：  $H(X) = E[I(X)] = -\sum_i^n p(x_i) \log p(x_i)$ ，表示平均每个事件种类的信息量。



**条件自信息:**  $I(x_i | y_j) = -\log p(x_i | y_j) \Rightarrow I(x_i | y_j) + I(y_j) = I(x_i, y_j)$

**联合熵:**  $H(X, Y) = \sum p(x_i, y_j) I(x_i, y_j)$ . 注意熵的重点是平均, 期望 Expectation.

**条件熵:**  $H(X | Y) = \sum p(x_i, y_j) \log p(x_i | y_j)$ . 熵的重点是信息量的期望, 因此使用  $p(x_i, y_j)$

**平均互信息:**  $I(X; Y) = H(X) - H(X | Y)$ , 使用了总体符号  $X$  的变量一般都具有平均的含义

互信息表示已知  $Y$  的话, 平均能够知道多少关于  $X$  的信息.  $H(X)$  表示  $X$  的信息量, 后面

$H(X | Y)$  表示知道  $Y$  以后,  $X$  还剩多少信息量. 因此两者之差就是  $Y$  能够挖掘的信息量.

**互信息:** 通过平均互信息的定义, 得到互信息的定义  $I(x_i; y_j) = \log \frac{p(x_i | y_j)}{p(x_i)}$

通常情况下, 知道  $y$  后  $p(x_i | y_j) > p(x_i)$ , 但这只是平均意义才行, 因此互信息有正有负.

**疑义度与噪声熵:** 互信息衍生的产品.  $H(X | Y)$  表示接收到  $y$ , 对  $x$  的怀疑程度.

$H(Y | X)$  表示发送  $X$ , 由于噪声产生的对  $Y$  的不确定度, 叫做噪声熵.

**条件互信息:**  $I(X; Y | Z) = I(X; Y, Z) - I(X; Y)$

**香农第一定理:** 可变长无失真信源编码定理. 编码规则为尽量等概.

**香农第二定理:** 有噪信道编码定理, 引入了信道的概念. 著名公式:

$$C = B \log(1 + S / N)$$

**香农第三定理:** 保失真度准则下的有失真信源编码定理. ...

熵定义的唯一形式可以参考之前写的博客—>熵的唯一性证明. 仅用三个条件便可证明.


条件一:  $H$  具有连续性.

条件二:  $H(\frac{1}{n}, \dots, \frac{1}{n})$  随  $n$  单调递增. (因为可能情况增加, 所以不确定度增加)

条件三: 熵的组合性质, 表示为:

$$H_m(p_1, p_2, \dots, p_m) = H_{m-1}(p_1 + p_2, p_3, \dots, p_m) + (p_1 + p_2) H_2(\frac{p_1}{p_1 + p_2}, \frac{p_2}{p_1 + p_2})$$

条件三的物理含义可理解为将抽取过程分段进行,但总体的熵不变.利用图例来进一步说明:



将单次随机抽取过程转化为二次抽取过程,阶段一为  $H(\frac{1}{2}, \frac{1}{2})$ , 同时有  $\frac{1}{2}$  的概率会进入阶段二,而阶段二的不确定熵为  $H(\frac{2}{3}, \frac{1}{3})$ , 但由于仅有  $\frac{1}{2}$  的概率会进入阶段二, 所以阶段二对总过程的不确定性的贡献为  $\frac{1}{2}H(\frac{2}{3}, \frac{1}{3})$ . 最终得到如下形式  $H(\frac{1}{2}, \frac{1}{3}, \frac{1}{6}) = H(\frac{1}{2}, \frac{1}{2}) + \frac{1}{2}H(\frac{2}{3}, \frac{1}{3})$


## 数据结构

**二叉搜索树**: 节点左大右小, 使用中序遍历能够从小到大输出节点. 最佳情况  $\log N$ .

**红黑树**: 为了使二叉搜索树平衡而建立的, 加入了颜色信息. 配合相关定义能使得各个叶子节点的高度差不超过 2. 有以下几条规则: (1) root 节点为黑色. (2) 叶子节点为黑色 (3) 红色节点的孩子节点都为黑色. (4) 任一一一条路径具有相同数目的黑色节点数量.

**B 树**: 类似红黑树, 但可以有很多子结点, 是一种平衡搜索树, 广泛应用在磁盘等设备上.

原因是二叉树的一次索引就需要访问磁盘一次, 如果同一个节点的子结点多了, 那树的高度就小多了, 因此访问 IO 的次数就减少了. B 树的每个节点关键字非降序排列, 因此对每个节点仅需比较两次便可知道索引点是否在该节点内. 并且非降序, 可用二分法快速索引内部的子结点.




**最小生成树**: 在一个图中, 利用树结构, 用最小的代价连接所有节点.

**Kruskal 算法**: 贪心的加边法. 代价排序, 如果边的两端为不同树, 则选择边, 融合两个子树.

如果为相同树, 则不选择此边, 重复上述过程, 得到最小生成树.

**Prim 算法:** 加点法, 利用一个队列, 不断加入当前 cur 的子结点, 然后判断子结点的代价, 如果子结点没在代价表内(map), 则加入此结点, 值为当前代价, 如果存在 map 中, 则判断是否更新该代价.



**KMP 算法:** 字符串匹配算法, 关键点在于寻找**最长公共前后缀**. 比如前缀内容出现在后缀中, 如下图所示的第二个 AB, 则下一次开始匹配的点就从 C 开始, C 之前是不可能匹配的.

BBC ABCDAB ABCDABCDABDE  
 ABCDABD

BBC ABCDAB ABCDABCDABDE  
 ABCDABD

## 线性代数部分

这部分其实在传统机器学习基础知识 和 PCA 与 SVD 部分已经总结的差不多了. 可自行查阅.